

LEAF

Levantamento e Estimativa de Anomalias Foliares

Pesquisa base para desenvolvimento de software de identificação de pragas, doenças e distúrbios foliares por imagem

Documento preparado para documentação do projeto e importação no NotebookLM

Projeto	LEAF - Levantamento e Estimativa de Anomalias Foliares
Objetivo	Apoiar a triagem visual de folhas por upload de imagem, distinguindo herbivoria/pragas, doenças e problemas abióticos ou de cuidado.
Uso previsto	Protótipo acadêmico com base científica, engenharia de prompt, visão computacional e relatório interpretável.
Data	21/05/2026

Resumo em uma frase: o LEAF deve primeiro verificar se a imagem é diagnóstica, depois segmentar folha e anomalia, medir severidade e só então classificar a causa provável com nível de confiança e justificativa visual.

Sumário

- 1. 1. Resumo executivo
- 2. 2. Escopo científico: o que o LEAF deve identificar
- 3. 3. Características eliminatórias primárias
- 4. 4. Guia de triagem visual por categoria
- 5. 5. Quantificação de área foliar e severidade
- 6. 6. Bases de dados, artigos e ferramentas de referência
- 7. 7. Arquitetura técnica recomendada para o protótipo
- 8. 8. Engenharia de prompt e relatório explicável
- 9. 9. Critérios de qualidade, limitações e riscos
- 10. 10. Checklist para vídeo e apresentação
- 11. 11. Referências e fontes para importar no NotebookLM

1. Resumo executivo

A ideia do LEAF é tecnicamente viável e tem boa base científica: combina métodos clássicos de análise de imagem, como ImageJ, LAMINA e Assess 2.0, com técnicas modernas de aprendizado profundo para classificação, detecção e segmentação de sintomas foliares. A proposta se diferencia ao tratar o resultado como triagem interpretável, e não como diagnóstico definitivo.

A literatura reforça três pontos centrais: (1) a imagem da folha carrega sinais úteis para reconhecer doenças e danos; (2) a medição objetiva de área afetada reduz subjetividade em comparação com avaliações visuais; (3) modelos treinados apenas em imagens controladas de laboratório tendem a falhar em condições reais de campo, exigindo datasets variados, controle de qualidade da imagem e comunicação de incerteza.

Para um projeto acadêmico com entrega em vídeo curto, o MVP mais forte é: upload da imagem, validação da foto, segmentação da folha, marcação da área suspeita, classificação em categorias amplas e geração de relatório simples: causa provável, evidências visuais, porcentagem aproximada de área afetada e recomendação segura de coletar mais informações ou consultar especialista quando a confiança for baixa.

Decisão de produto	Recomendação para o LEAF	Justificativa
Não prometer diagnóstico absoluto	Usar termos como 'suspeita', 'indício', 'compatível com' e 'nível de confiança'.	Sintomas de pragas, doenças e estresses abióticos se sobrepõem visualmente [R02, R04].
Separar triagem e severidade	Classificar a causa provável e calcular a área afetada em etapas diferentes.	A severidade é uma medida de área/porcentagem; a causa é uma classificação biológica/agronômica [R09, R10].
Ter classe 'incerto/misto'	Quando sinais forem contraditórios, retornar 'misto' ou pedir novas fotos.	Dano de inseto pode abrir porta para fungos/bactérias; estresse abiótico pode predispor a doenças [R02, R03].
Não recomendar pesticida específico	Orientar inspeção, isolamento, remoção de folhas muito afetadas e consulta local.	Recomendação fitossanitária depende de cultura, região, legislação e estágio da planta.

2. Escopo científico: o que o LEAF deve identificar

Para o protótipo, o LEAF deve trabalhar com classes amplas e visualmente defensáveis. A classificação por espécie de patógeno, inseto ou deficiência nutricional exata exige base de dados específica, confirmação por especialista e, em muitos casos, análise laboratorial.

Classe macro	O que inclui	Indícios visuais comuns	Saída recomendada
Pragas/herbivoria	Insetos mastigadores, minadores, sugadores, raspadores e, em sentido amplo, ácaros.	Fuross, bordas comidas, trilhas de minador, pontuações, teias, ovos, frass, larvas ou insetos visíveis.	Suspeita de dano por praga/inseto; medir área perdida ou área raspada.

Doenças fúngicas/oomicetos	Ferrugens, míldios, oídios, manchas foliares, antracnoses, requeimas.	Manchas necróticas, halos, pó branco, mofo, pústulas, esporos, lesões circulares ou irregulares.	Suspeita de doença fúngica/oomiceto; medir área sintomática.
Doenças bacterianas	Manchas bacterianas, crestamentos, murchas e podridões associadas a bactérias.	Lesões encharcadas, manchas angulares entre nervuras, halos amarelos, exsudação, aspecto translúcido.	Suspeita de doença bacteriana; recomendar confirmação e evitar molhar folhas.
Doenças virais	Viroses transmitidas por vetores, mosaicos, deformações e nanismo.	Mosaico verde-claro/verde-escuro, enrugamento, folhas deformadas, anéis, crescimento reduzido.	Suspeita viral; baixa confiança se houver apenas uma folha.
Situações abióticas/cuidados	Deficiência/excesso nutricional, água, sol, frio/calor, salinidade, herbicida, vento, granizo, dano mecânico.	Padrão uniforme ou geométrico, simetria, distribuição por idade da folha, margens queimadas, clorose interveinal sem sinais do agente.	Provável estresse/cuidado; pedir contexto ambiental e histórico.
Folha saudável/incerto	Imagem sem dano relevante, imagem ruim ou caso misto.	Poucos sintomas, baixa nitidez, fundo confuso, múltiplas causas possíveis.	Sem anomalia clara ou resultado inconclusivo.

3. Características eliminatórias primárias

As características abaixo funcionam como filtros de primeira decisão. Elas não fecham diagnóstico, mas ajudam a eliminar hipóteses improváveis e orientar a interface do software.

Pergunta eliminatória	Se SIM, favorece	Se NÃO, considerar	Observação
Há tecido faltando, buracos ou bordas consumidas?	Herbivoria por insetos mastigadores ou dano mecânico.	Doenças e deficiências normalmente alteram cor/estrutura, mas não removem tecido de forma limpa.	Verificar frass, ovos, larvas e padrão repetido antes de concluir inseto.
Há trilhas sinuosas, manchas internas ou túneis dentro da folha?	Minadores de folha.	Mancha foliar fúngica/bacteriana se a lesão não for túnel e tiver halo/necrose.	Minadores formam minas sinuosas ou manchas entre epiderme superior e inferior [R06, R07].
Há pó, mofo, pústulas ou esporos visíveis?	Doença fúngica/oomiceto.	Vírus, bactéria, insetos e abiótico se não houver sinal do patógeno.	Sinais do agente são mais específicos que sintomas [R02].
As lesões parecem encharcadas/translúcidas ou com halo amarelo?	Doença bacteriana ou fase inicial de algumas doenças fúngicas.	Deficiência, sol, herbicida, mastigação ou necrose antiga.	Lesões bacterianas podem apresentar aspecto encharcado e halo [R04].
Existe padrão de mosaico, deformação ou enrugamento sem fungo visível?	Virose ou fitotoxicidade/herbicida.	Fungo/bactéria se houver lesões localizadas e sinais de agente.	Vírus não são visíveis a olho nu; dependem de sintomas e contexto [R04].
O padrão aparece em muitas folhas de modo uniforme/geométrico?	Distúrbio abiótico ou manejo/cuidado.	Praga/doença se distribuição for em focos, manchas irregulares ou se houver sinais do agente.	Padrões geométricos regulares sugerem manejo/cultivo; nutrientes móveis/ imóveis afetam folhas diferentes [R05].
A imagem está borrada, escura, distante ou sem folha central?	Rejeitar análise automática.	Prosseguir apenas se folha e anomalia estiverem claras.	A qualidade da entrada é um requisito de engenharia, não detalhe visual.

4. Guia de triagem visual por categoria

4.1 Pragas, insetos e herbivoria

A herbivoria é o consumo de tecido vegetal por animais, geralmente insetos no contexto de folhas. Para o LEAF, o principal desafio é separar dano real por inseto de rasgos por vento, granizo, manuseio, poda ou queimaduras que deixam bordas mortas.

Subtipo	Marcadores visuais	Como o algoritmo pode detectar	Cuidado
Mastigadores	Buracos, bordas comidas, recortes irregulares, esqueletização entre nervuras.	Segmentar folha; detectar área faltante; comparar contorno esperado da folha; contar buracos internos.	Granizo e rasgo mecânico também removem tecido.
Minadores	Linhas brancas/cinzas sinuosas, túneis serpentinados ou manchas internas; possível frass dentro da mina.	Detectar estruturas finas de alto contraste dentro da folha; classificar formato sinuoso/blotch.	Manchas fúngicas podem parecer manchas internas, mas não seguem túnel.
Sugadores/raspadores	Pontuações claras, prateamento, amarelecimento localizado, deformação; pode haver teias ou insetos minúsculos.	Textura fina, padrão de stippling, contraste local, detecção de teias/pontos.	Deficiência e sol também geram clorose/amarelecimento.
Presença direta	Inseto, larva, ovos, exúvias, teias ou fezes/frass.	Deteção de objetos pequenos e sugestão de zoom/segunda foto.	Uma foto comum pode não ter resolução suficiente.

- Para herbivoria, medir apenas a área ausente pode subestimar dano por raspagem ou sucção, pois nesses casos a folha continua presente, mas fisiologicamente danificada.
- BioLeaf é uma referência importante porque estima perda foliar por imagem e usa reconstrução de contorno para folhas com dano na borda [R08].
- O resultado ideal para o usuário é: 'há sinais compatíveis com praga/herbivoria', 'tipo visual provável', 'porcentagem estimada' e 'precisa de inspeção do verso da folha'.

4.2 Doenças foliares

Doenças de plantas podem ser causadas por fungos, bactérias, vírus, oomicetos, nematoides e outros agentes. Em imagem foliar comum, o LEAF consegue observar sintomas e alguns sinais; não consegue confirmar agente etiológico sem contexto, microscopia ou teste laboratorial.

Grupo provável	Marcadores visuais fortes	Marcadores fracos	Mensagem segura
Fúngica/oomiceto	Pó branco/cinza, mofo, esporos, pústulas, manchas com anéis, ferrugem, míldio.	Clorose e necrose sem sinal do agente.	'Compatível com doença fúngica/oomiceto; confirmar com contexto da cultura e evolução.'
Bacteriana	Lesões encharcadas, halo amarelo, manchas angulares delimitadas por nervuras, exsudação.	Mancha marrom genérica.	'Compatível com mancha bacteriana/crestamento; evite molhar folhas e confirme localmente.'
Viral	Mosaico, deformação, crinkle/enrugamento, anéis, nanismo, padrões sistêmicos.	Amarelecimento genérico.	'Compatível com virose/fitotoxicidade; imagem isolada não confirma.'
Doença vascular/raiz refletida na folha	Murcha generalizada, amarelecimento e colapso sem lesão foliar local clara.	Folha murcha em vaso seco.	'A folha indica estresse sistêmico; o software precisa de foto da planta inteira e substrato.'

4.3 Situações abióticas, natureza e cuidados

Problemas abióticos são causados por fatores não vivos: água, temperatura, radiação, solo, nutrientes, salinidade, produtos químicos, vento, granizo, dano mecânico e manejo. O diagnóstico visual é difícil porque vários sintomas também aparecem em doenças.

Causa provável	Padrão visual	Pergunta que o LEAF deve fazer	Indício eliminatório
Deficiência nutricional	Clorose, clorose interveinal, necrose de margens/pontas, coloração roxa/bronze.	O sintoma começou em folhas velhas ou novas? Houve adubação?	Nutrientes móveis aparecem primeiro em folhas velhas; imóveis em folhas novas [R05].
Excesso/falta de água	Murcha, amarelecimento geral, manchas aquosas ou necrose em borda, queda foliar.	Solo está encharcado ou seco? Há drenagem?	Sem sinais de patógeno; afeta várias folhas de modo semelhante.
Sol/calor/frio	Queimadura, áreas	A planta mudou de local?	Padrão no lado exposto ou

	descoloridas expostas, escaldadura, necrose marginal.	Pegou sol direto/frio intenso?	após evento climático.
Fitotoxicidade/herbicida	Deformação, mosaico irregular, necrose em pontas, padrão em deriva ou aplicação.	Foi aplicado produto recentemente?	Padrão geométrico ou em faixa no local/vaso/canteiro.
Dano mecânico/natureza	Rasgos, furos grandes, amassados, bordas quebradas, marcas de granizo.	Houve vento, transporte, poda, pets, chuva forte?	Tecido rasgado sem frass, ovos, inseto ou progressão de lesões.

5. Quantificação de área foliar e severidade

O diferencial técnico do LEAF não deve ser apenas dizer 'é doença' ou 'é praga', mas medir quanto da folha está afetado. Essa parte aproxima o projeto do ImageJ, Leaf Doctor, Assess 2.0, LAMINA e BioLeaf.

Métrica	Fórmula conceitual	Uso no LEAF
Área foliar presente	$A_{\text{folha}} = \text{pixels_da_folha} \times \text{escala}^2$	Mostrar tamanho relativo da folha e base para porcentagens.
Severidade de doença	$\% \text{ afetada} = \frac{\text{pixels_sintomáticos}}{\text{pixels_da_folha}} \times 100$	Medir manchas, clorose, necrose ou mofo dentro da folha.
Herbivoria por área ausente	$\% \text{ perda} = \frac{(\text{área_reconstruída} - \text{área_presente})}{\text{área_reconstruída}} \times 100$	Estimativa para buracos e bordas comidas.
Contagem de lesões	número de componentes conectados	Diferenciar poucos pontos grandes de muitos pontos pequenos.
Índice de confiança	combinação de qualidade da imagem + confiança do modelo + coerência dos sinais	Evitar respostas fortes em fotos ruins ou casos mistos.

- Segmentação mínima: fundo, folha saudável e área sintomática. Esse esquema é amplamente usado para estimar severidade foliar por imagem [R10].
- ImageJ é útil como referência metodológica porque permite medir área e lesões por limiarização; estudos recentes comparam ImageJ a métodos de machine learning para severidade de lesões [R09].
- Para folhas com bordas comidas, a reconstrução do contorno é mais difícil do que segmentar manchas internas. A literatura do BioLeaf é importante por trabalhar com dano de borda usando Bezier/Otsu [R08].
- Para apresentação do projeto, a porcentagem estimada é visualmente forte: o vídeo pode mostrar a imagem original, a máscara destacada e o relatório final.

Etapas de visão computacional	Técnicas recomendadas	Resultado esperado
Validação da foto	Blur score, brilho, contraste, detecção de folha central, dimensão mínima.	Aceitar, pedir nova foto ou informar baixa confiança.
Segmentação da folha	HSV/CIELAB + threshold adaptativo; U-Net/DeepLab/Mask R-CNN em versão avançada.	Máscara da folha e remoção do fundo.
Segmentação da anomalia	Otsu/adaptativo, índices RGB/HSV, textura GLCM, U-Net leve.	Máscara de manchas, necrose, clorose, furos ou minas.
Classificação macro	CNN leve como MobileNet/EfficientNet; ensemble com regras visuais.	Praga, fúngica, bacteriana, viral, abiótica ou incerto.
Explicação	Overlay, bounding boxes, Grad-CAM, texto gerado por prompt controlado.	Usuário entende por que o LEAF chegou ao resultado.

6. Bases de dados, artigos e ferramentas de referência

As fontes abaixo são as mais relevantes para alimentar o NotebookLM e fundamentar a apresentação. A seleção mistura artigos completos, guias técnicos, datasets e softwares comparáveis.

Fonte	Tipo	Resultado/uso relevante para o LEAF	Prioridade
Embrapa Manual Básico de Técnicas Fitopatológicas [R01]	PDF técnico	Define sintomas, sinais, pragas e lista termos como clorose, mosaico, mancha,	Alta

		galha e anasarca.	
APS Plant Disease Diagnosis [R02]	Guia técnico	Diferencia sintomas e sinais; cita micélio, esporos, frass, ovos, teias e exsudação bacteriana.	Alta
MSU Signs and symptoms [R04]	Extensão	Resumo visual de sinais/sintomas fúngicos, bacterianos e virais.	Alta
BioLeaf [R08]	Artigo completo	Medição de herbivoria; segmentação Otsu + curvas de Bezier; precisão comparável a especialistas.	Alta
ImageJ vs ML em mandioca [R09]	Artigo completo	Mostra medição de severidade com ImageJ e ML; ressalta vantagens e limitações.	Alta
PlantVillage [R11]	Dataset	54.303 imagens saudáveis/doentes em 38 categorias por espécie/doença.	Alta
PlantDoc [R12]	Dataset	2.598 imagens reais em 13 espécies e até 17 classes de doença; mais próximo do campo.	Alta
Cassava TFDS [R13]	Dataset	9.430 imagens de mandioca: saudável e quatro condições/doenças/danos.	Média
Pacal et al. revisão sistemática [R14]	Revisão	Analisa 160 artigos de 2020 a 2024; orienta escolha de modelos e gaps.	Alta
Avaliação de apps [R15]	Artigo	Compara 17 apps; Plantix se destaca, mas funcionalidade geral ainda é limitada.	Alta
Assess 2.0 e LAMINA [R16, R17]	Software	Comparáveis ao ImageJ; medição de área, doença, lesões, forma e área ausente.	Média
Benchmark Scientific Reports [R19]	Artigo	Mostra que datasets e modelos ainda não têm consenso; alerta para generalização.	Alta
Multi-dataset approach [R20]	Artigo	PlantDoc + imagens web aumenta realismo; desempenho varia em cenário diverso.	Média

7. Arquitetura técnica recomendada para o protótipo

Como projeto de engenharia de software, o LEAF deve ser desenhado em camadas. Mesmo que o primeiro MVP use modelos prontos ou APIs, a documentação precisa mostrar uma arquitetura coerente.

Camada	Responsabilidade	Tecnologias possíveis	MVP sugerido
Interface	Upload/câmera, pré-visualização, resultado e histórico.	React/Vite, HTML/CSS/JS, Streamlit ou Gradio.	Web responsiva com drag-and-drop e botão 'Analisar folha'.
Pré-processamento	Validar qualidade, redimensionar, normalizar cor, remover fundo.	OpenCV, Pillow, scikit-image.	OpenCV + regras simples de qualidade.
Segmentação	Separar folha, fundo e área suspeita.	U-Net, DeepLab, Mask R-CNN, threshold HSV/Otsu.	Threshold + morfologia para demo; U-Net se houver dataset.
Classificação	Classificar a causa provável.	MobileNetV3, EfficientNet, ResNet, ConvNeXt, Roboflow/Teachable Machine.	Modelo leve com classes macro.
Relatório	Traduzir dados técnicos para linguagem do usuário.	LLM com prompt controlado, template de texto, regras de segurança.	Template + prompt de justificativa.
Banco/histórico	Salvar imagem, resultado,	SQLite, Supabase, Firebase.	JSON local ou SQLite.

	confiança e data.		
--	-------------------	--	--

12. Usuário envia imagem.
13. Sistema valida se a folha está nítida, iluminada e centralizada.
14. Modelo/algoritmo separa folha do fundo.
15. Sistema localiza regiões anormais: manchas, furos, minas, clorose, necrose ou área ausente.
16. Classificador estima categoria macro e confiança.
17. Módulo de relatório gera resposta com evidências visuais e limites de certeza.
18. Interface exhibe original + máscara + porcentagem + orientação segura.

8. Engenharia de prompt e relatório explicável

A engenharia de prompt deve ser usada para transformar a saída técnica do modelo em um relatório seguro, compreensível e consistente. O prompt não deve 'adivinhar' diagnóstico; deve obedecer aos campos calculados pelo sistema.

Campo de entrada para o prompt	Exemplo
classe_modelo	praga_herbivoria
confianca	0,78
area_afetada_percentual	12,4%
marcadores_visuais	bordas comidas; furos internos; sem mofo visível
qualidade_imagem	boa
observacoes_usuario	planta em vaso; apareceu há 3 dias

Prompt base recomendado: Você é o módulo de relatório do software LEAF. Use apenas os dados fornecidos pelo sistema. Não afirme diagnóstico definitivo. Classifique como suspeita provável, explique os sinais visuais, informe a severidade estimada e peça novas informações quando a confiança for baixa. Não recomende pesticidas específicos. Formato: 1) Resultado provável; 2) Evidências observadas; 3) Severidade; 4) Limitações; 5) Próximas ações seguras.

Regra de segurança	Por quê
Se confiança < 0,60, retornar 'inconclusivo' e pedir nova foto.	Evita falsa certeza em imagem ruim ou caso misto.
Se houver sinais de praga e doença ao mesmo tempo, usar classe 'misto'.	Ferimentos de inseto podem gerar infecção secundária.
Sempre diferenciar 'sintoma' de 'sinal'.	Sinal é evidência do agente; sintoma é reação da planta [R01, R02].
Não sugerir defensivo ou dosagem.	Depende de cultura, legislação, região, estágio e manejo.

9. Critérios de qualidade, limitações e riscos

Risco	Impacto	Como mitigar no LEAF
Fotos de laboratório x campo	Modelo parece ótimo em dataset limpo, mas falha em fotos reais.	Treinar/testar com fundos variados, iluminação real e PlantDoc/web images.
Sintomas semelhantes	Abiótico, virose, deficiência e herbicida podem parecer iguais.	Usar perguntas de contexto e classe 'incerto'.
Dataset desbalanceado	Modelo aprende classes majoritárias e ignora raras.	Balanceamento, augmentação, métricas por classe e matriz de confusão.
Folha errada ou planta desconhecida	Doenças são específicas por cultura.	Adicionar campo 'qual é a planta?' e detectar espécie em etapa separada.
Recomendação perigosa	Usuário aplica produto indevido.	Focar em triagem e orientação de confirmação; nada de dosagem.
Falso negativo	Usuário ignora problema real.	Mostrar limites: 'não detectado na imagem' não significa planta saudável.

- Métrica mínima para apresentar: acurácia geral, precisão/recall por classe, matriz de confusão e exemplos de acerto/erro.
- Métrica de segmentação se houver máscara: IoU ou Dice entre máscara prevista e máscara manual.
- Métrica de severidade: erro absoluto médio entre porcentagem prevista e anotação manual/ImageJ.
- No vídeo, mostrar pelo menos um exemplo certo e um caso de baixa confiança. Isso passa maturidade de engenharia.

10. Checklist para vídeo e apresentação

Parte do vídeo	Conteúdo sugerido	Tempo
Abertura	Problema: identificar pragas/doenças por imagem e estimar área afetada.	30s
Base científica	Explicar sintomas, sinais, herbivoria, doenças e abióticos com 3 referências.	50s
Ferramenta de IA	Mostrar modelo/classificador usado e como o prompt transforma resultado em relatório.	60s
Prompt	Exibir prompt base de relatório seguro e explicar regras de confiança.	40s
Demonstração	Upload da imagem, máscara da área afetada, porcentagem e resultado.	90s
Fechamento	Limitações, próximos passos e valor do LEAF.	30s

- Frase forte para apresentação: 'O LEAF não substitui um agrônomo; ele organiza evidências visuais e reduz subjetividade na triagem inicial'.
- Mostrar comparativo visual com ImageJ/Plantix: o LEAF combina quantificação de área afetada com relatório moderno e explicável.
- Use uma identidade visual limpa: verde escuro, verde claro, fundo branco, cards, upload central e relatório com etiquetas de confiança.

11. Referências e fontes para importar no NotebookLM

Sugestão de uso: importe este PDF no NotebookLM e, adicionalmente, adicione as fontes abaixo como URLs ou PDFs separados. Priorize R01, R02, R04, R08, R09, R11, R12, R14 e R15.

[R01] Embrapa - Manual Básico de Técnicas Fitopatológicas. PDF técnico em português; define sintomas, sinais, pragas e doenças no contexto fitopatológico. [Acessar fonte](#)

[R02] APS - Plant Disease Diagnosis. Guia técnico sobre diagnóstico, sinais de agentes bióticos, micélio, esporos, frass, ovos, exsudação bacteriana e sintomas. [Acessar fonte](#)

[R03] APS - Introduction to Abiotic Disorders in Plants. Base para diferenciar distúrbios não infecciosos de doenças e pragas. [Acessar fonte](#)

[R04] MSU Extension - Signs and symptoms of plant disease: fungal, viral or bacterial. Resumo prático de sinais e sintomas de doenças fúngicas, bacterianas e virais. [Acessar fonte](#)

[R05] Iowa State University Extension - Nutrient Deficiencies and Application Injuries in Field Crops. PDF com padrões de deficiências nutricionais e lesões por aplicação/cultivo. [Acessar fonte](#)

[R06] University of Minnesota Extension - Leafminers in home gardens. Guia de sintomas visuais de minadores: minas sinuosas e manchas nas folhas. [Acessar fonte](#)

[R07] Utah State University Extension - Leafminers of Vegetable Crops. PDF técnico sobre dano de minadores, frass, túneis serpentinados, pontuações e impacto na fotossíntese. [Acessar fonte](#)

[R08] Machado et al. - BioLeaf: mobile app to measure foliar damage caused by insect herbivory. Artigo sobre medição automática de dano foliar por herbivoria com segmentação de Otsu e curvas de Bezier. [Acessar fonte](#)

[R09] Elliott et al. - Comparison of ImageJ and machine-learning image analysis for cassava bacterial blight. Artigo de Plant Methods comparando ImageJ e SVM/few-shot para severidade de lesões de mandioca. [Acessar fonte](#)

[R10] R4PDE - Measuring foliar severity. Material didático-científico sobre cálculo de severidade por segmentação de pixels: doente, saudável e fundo. [Acessar fonte](#)

[R11] TensorFlow Datasets - PlantVillage. Catálogo do dataset PlantVillage: imagens saudáveis/doentes por espécie e doença. [Acessar fonte](#)

[R12] PlantDoc Dataset - GitHub. Dataset com imagens reais para detecção visual de doenças de plantas. [Acessar fonte](#)

[R13] TensorFlow Datasets - Cassava. Dataset de mandioca com folhas saudáveis e quatro condições/danos/doenças. [Acessar fonte](#)

[R14] Pacal et al. - Systematic review of deep learning techniques for plant diseases. Revisão sistemática de 160 artigos entre 2020 e 2024 sobre classificação, detecção e segmentação. [Acessar fonte](#)

[R15] Siddiqua et al. - Evaluating Plant Disease Detection Mobile Applications. Avaliação de 17 aplicativos móveis de diagnóstico vegetal, incluindo Plantix e Leaf Doctor. [Acessar fonte](#)

[R16] Quantitative Plant - Assess 2.0. Base sobre software de quantificação de doença, área foliar, lesão e porcentagem de doença. [Acessar fonte](#)

[R17] Quantitative Plant - LAMINA. Ferramenta para quantificar área, forma e área ausente em folhas. [Acessar fonte](#)

[R18] CGIAR Big Data - Plantix case study. Estudo de caso sobre Plantix, geotagging, base de imagens e escala de uso. [Acessar fonte](#)

[R19] Richter & Kim - Comprehensive benchmark of transfer learning on open datasets. Benchmark recente de CNNs em datasets abertos; alerta sobre falta de consenso e generalização campo/laboratório. [Acessar fonte](#)

[R20] Krishna - Plant Leaf Disease Detection Using Deep Learning: A Multi-Dataset Approach. Estudo 2025 com PlantDoc + imagens web; avalia EfficientNet, ResNet e DenseNet em condições mais diversas. [Acessar fonte](#)

[R21] Frontiers in Plant Science - Review of plant leaf disease identification by deep learning algorithms. Revisão 2025 com panorama de bases de dados e algoritmos recentes. [Acessar fonte](#)

Anexo A - Vocabulário rápido para o LEAF

Termo	Definição operacional para o software
Sintoma	Reação visível da planta: clorose, necrose, mancha, murcha, deformação, mosaico.
Sinal	Evidência física do agente: micélio, esporos, frass, ovos, inseto, teia, exsudação.
Severidade	Porcentagem da área da folha/órgão com sintoma ou dano.
Incidência	Proporção de folhas/plantas afetadas no conjunto observado.
Herbivoria	Consumo ou dano de tecido vegetal por animal, no escopo do LEAF principalmente insetos.
Abiótico	Problema causado por fator não vivo: água, temperatura, luz, solo, nutrientes, química, mecânica.
Máscara	Imagem binária ou semântica que marca onde está a folha e onde está a anomalia.
Confiança	Medida calculada que combina probabilidade do modelo, qualidade da imagem e coerência das regras visuais.